Windy Gridworld 报告

算法描述

两种方法均维护动作价值函数 Q(s,a)，行为策略采用 epsilon-greedy：以概率 epsilon=0.1 随机选择动作，否则选择当前 Q 值最大的动作。学习率 alpha=0.5，折扣因子为 gamma=1.0，训练 1,000,000 个回合。

SARSA

SARSA 是 on-policy 方法。环境执行当前 epsilon-greedy 动作 a 后，在下一状态 s' 继续依据同一 epsilon-greedy 策略选出 a'，并按下式更新：
Q(s,a) <- Q(s,a) + alpha * [r + gamma * Q(s',a') - Q(s,a)]
到达终点时没有下一动作，更新目标仅为即时奖励 r。

Q-Learning

Q-Learning 是 off-policy 方法。行为仍使用 epsilon-greedy 探索，但更新时采用下一状态的最大动作价值：
Q(s,a) <- Q(s,a) + alpha * [r + gamma * max_a' Q(s',a') - Q(s,a)]
到达终点时更新目标仅为即时奖励。

实验结果截图

